

Universidade Estadual de Campinas
Instituto de Matemática, Estatística e Computação Científica

Relatório Científico — Iniciação Científica FAPESP

Otimização do Portfólio de Merton Através de Controle Estocástico Ótimo

Processo 2025/07615-8
1 de agosto de 2025 – 31 de julho de 2026

Bolsista:
Guilherme Valverde Freiria
Supervisor:
Prof. Dr. Luiz Koodi Hotta

Campinas, SP
4 de agosto de 2026

Resumo

Este trabalho estuda o problema clássico de Merton de alocação ótima de portfólio em tempo contínuo, utilizando a teoria de controle estocástico e a equação de Hamilton–Jacobi–Bellman para obter a estratégia ótima em forma fechada. Em seguida, por meio de simulação de Monte Carlo, avalia-se o custo, em termos de equivalente de certeza, de substituir o rebalanceamento contínuo por rebalanceamentos discretos, mostrando que a perda de utilidade cresce de forma não linear conforme aumenta o intervalo entre ajustes.

Palavras-chave: controle estocástico; equação de Hamilton–Jacobi–Bellman; problema de Merton; alocação de portfólio; simulação de Monte Carlo.

1 Introdução

Problemas de controle estocástico desempenham um papel fundamental na modelagem financeira. Um exemplo clássico é o problema de investimento ótimo em tempo contínuo proposto por Merton (1971), no qual o investidor escolhe dinamicamente a alocação de sua riqueza entre um ativo livre de risco e um ativo sob incerteza (risco), com o objetivo de maximizar a utilidade esperada da riqueza futura.

De modo geral, um problema de controle estocástico consiste em otimizar o valor esperado de uma função de ganho ou custo por meio da escolha de uma estratégia admissível que influencia a dinâmica de um sistema estocástico. Embora o agente possa afetar a evolução do sistema, ele permanece sujeito à incerteza inerente aos fatores aleatórios do ambiente econômico.

A principal ferramenta para a resolução desses problemas é o Princípio da Programação Dinâmica (Dynamic Programming Principle — DPP), cuja formulação infinitesimal conduz à equação de Hamilton–Jacobi–Bellman (HJB), uma equação diferencial parcial não linear que caracteriza a função valor. O restante deste trabalho está organizado da seguinte forma: a Seção 2 revisa os elementos de cálculo estocástico necessários para o desenvolvimento da teoria; a Seção 3 apresenta a formulação geral do controle estocástico ótimo e a equação HJB; a Seção 4 aplica esse arcabouço ao problema clássico de Merton, obtendo soluções explícitas; a Seção 5 avalia, por meio de simulação de Monte Carlo, o impacto econômico de se substituir o rebalanceamento contínuo por rebalanceamentos discretos; e a Seção 6 apresenta as conclusões do trabalho.

2 Elementos de Cálculo Estocástico

Esta seção apresenta as principais ferramentas matemáticas que servem de base para o desenvolvimento do restante do trabalho, em particular o estudo de processos estocásticos e equações de difusão. De acordo com (Hull, 2016, p. 394), qualquer variável cujo valor evolui ao longo do tempo de forma incerta pode ser descrita por um processo estocástico. No contexto

de modelagem de ativos financeiros em tempo contínuo, o objeto fundamental é o processo de Wiener, também conhecido como movimento Browniano.

2.1 O Processo de Wiener

Formalmente, um processo estocástico $W = (W_t)_{t\geq 0}$, em que $t \geq 0$ denota o tempo contínuo, é denominado processo de Wiener se satisfaz as seguintes propriedades (Björk, 2019, p. 43): parte do valor $W_0 = 0$; possui incrementos independentes, isto é, para $r < s \leq t < u$ as variáveis $W_u - W_t$ e $W_s - W_r$ são independentes; para $s < t$, o incremento $W_t - W_s$ possui distribuição normal $N(0, t-s)$; e, por fim, possui trajetórias contínuas. Apesar da continuidade, as trajetórias de um processo de Wiener são, com probabilidade um, não diferenciáveis em nenhum ponto e apresentam variação total localmente infinita (Björk, 2019, p. 44). Essa característica torna o cálculo clássico inadequado para lidar com esse tipo de processo, motivando o desenvolvimento do cálculo estocástico.

2.2 Equações Diferenciais Estocásticas (EDE)

Uma vez estabelecidas as propriedades do processo de Wiener, é possível utilizá-lo como fonte de aleatoriedade na modelagem da dinâmica de outros processos. Uma Equação Diferencial Estocástica (EDE) descreve a dinâmica de um processo estocástico X, em particular, de um processo de difusão de Itô, amplamente utilizado na modelagem da dinâmica de ativos financeiros (Pham, 2009, p. 17). Formalmente, tal equação pode ser expressa como (Björk, 2019, p. 67):

$$dX_t = \mu(t, X_t)\, dt + \sigma(t, X_t)\, dW_t, \quad X_0 = x_0. \tag{1}$$

Aqui, $\mu(t, X_t)$ é uma função que representa o termo de *drift* (tendência), enquanto $\sigma(t, X_t)$ representa o termo de difusão (volatilidade). Além disso, $X_0 = x_0 \in \mathbb{R}$ denota o valor inicial do processo. A notação diferencial apresentada na equação (1) constitui uma forma abreviada da seguinte equação integral:

$$X_t = x_0 + \int_0^t \mu(s, X_s)\, ds + \int_0^t \sigma(s, X_s)\, dW_s. \tag{2}$$

Sob condições de regularidade, especificamente se μ e σ satisfazem condições de Lipschitz e crescimento linear, existe uma única solução para a EDE, adaptada à filtração do processo de Wiener e com trajetórias contínuas (Björk, 2019, p. 67).

2.3 Lema de Itô

Definida a EDE, resta apresentar a ferramenta que permite manipulá-la e, quando satisfeitas as condições de regularidade, obter soluções explícitas: o Lema de Itô. Seja X_t um processo que satisfaz uma EDE e seja $f(t, x)$ uma função de classe $C^{1,2}$. Então, o processo $Z_t = f(t, X_t)$ satisfaz (Björk, 2019, p. 54):

$$df(t, X_t) = \left(\frac{\partial f}{\partial t} + \mu_t \frac{\partial f}{\partial x} + \frac{1}{2}\sigma_t^2 \frac{\partial^2 f}{\partial x^2} \right) dt + \sigma_t \frac{\partial f}{\partial x} dW_t, \tag{3}$$

em que μ_t representa o termo de drift local, ou seja, a tendência esperada do processo, enquanto σ_t denota o termo de difusão. O termo dW_t refere-se ao incremento de um processo de Wiener, também conhecido como movimento Browniano, responsável por introduzir a incerteza estocástica no sistema. As derivadas parciais $\frac{\partial f}{\partial t}$, $\frac{\partial f}{\partial x}$ e $\frac{\partial^2 f}{\partial x^2}$ devem ser interpretadas como derivadas da função determinística $f(t, x)$. O termo $\frac{1}{2}\sigma_t^2 \frac{\partial^2 f}{\partial x^2}$ corresponde à correção de Itô, a qual surge da variação quadrática não nula das trajetórias do processo de Wiener, que são contínuas, mas não diferenciáveis. A demonstração do lema de Itô baseia-se nas relações fundamentais do cálculo estocástico, dadas por $(dt)^2 = 0$, $dt \cdot dW_t = 0$ e $(dW_t)^2 = dt$.

Essa fórmula desempenha um papel central no cálculo estocástico, pois permite transformar Equações Diferenciais Estocásticas em expressões diferenciais ou integrais mais tratáveis. Além disso, o Lema de Itô é fundamental na derivação da equação de Hamilton Jacobi Bellman, que será apresentada na seção seguinte.

3 Controle Estocástico Ótimo

3.1 Controle para Processos de Difusão

Problemas de controle estocástico surgem naturalmente em diversas áreas da modelagem financeira, tendo como objetivo maximizar (ou minimizar) uma função de ganho (perda) esperado ao longo do tempo (Cartea et al., 2015, p. 101). Para formular esse problema, considere um processo de controle $u = (u_t)_{0 \le t \le T}$, com valores em $\mathbb{R}^p$, e um processo de estado controlado $X^u = (X_t^u)_{0 \le t \le T}$, com valores em $\mathbb{R}^n$. Supõe-se que o processo de estado evolua de acordo com a difusão de Itô

$$dX_t^u = \mu(t, X_t^u, u_t)\, dt + \sigma(t, X_t^u, u_t)\, dW_t, \qquad X_0^u = x, \tag{4}$$

em que $(W_t)_{0 \le t \le T}$ é um vetor de movimentos Brownianos independentes.

O conjunto $\mathcal{A}_{0,T}$, denominado conjunto de controles admissíveis, é composto por processos $\mathcal{F}$-previsíveis para os quais (4) admite uma solução forte. A previsibilidade garante que o agente não utilize informações futuras, o que tornaria o problema irreal. Assume-se que os coeficientes μ e σ satisfazem condições de Lipschitz contínuas (Cartea et al., 2015, p. 104).

Para um controle admissível $u \in \mathcal{A}_{0,T}$, define-se o critério de desempenho por

$$H^u(x) = \mathbb{E}\left[G(X_T^u) + \int_0^T F(s, X_s^u, u_s)\, ds \right], \tag{5}$$

em que $G : \mathbb{R}^n \to \mathbb{R}$ representa a recompensa terminal e $F : \mathbb{R}_+ \times \mathbb{R}^{n+p} \to \mathbb{R}$ representa o ganho ou custo acumulado. Assume-se que as funções G e F são limitadas. O objetivo do agente consiste em escolher um controle admissível que maximize o critério de desempenho. Dessa forma, a função valor do problema é definida por

$$H(x) = \sup_{u \in \mathcal{A}_{0,T}} \mathbb{E}\left[G(X_T^u) + \int_0^T F(s, X_s^u, u_s)\, ds \right]. \tag{6}$$

A função valor representa, portanto, o maior ganho esperado que pode ser obtido pelo agente a partir do estado inicial x, considerando que suas decisões de controle influenciam a dinâmica futura do sistema por meio de (4). Esse efeito caracteriza a retroalimentação presente no problema de controle estocástico. Em vez de resolver diretamente o problema de otimização definido em (6), utiliza-se o Princípio da Programação Dinâmica, apresentado a seguir.

Teorema 1 (Dynamic Programming Principle for Diffusions)**.** *A função valor* (6) *satisfaz:*

$$H(t,x) = \sup_{u \in \mathcal{A}_{t,T}} \mathbb{E}_{t,x}\left[H(\tau, X_\tau^u) + \int_t^\tau F(s, X_s^u, u_s)\, ds \right], \tag{7}$$

para todo $(t,x) \in [0,T] \times \mathbb{R}^n$ *e todo tempo de parada* $\tau \leq T$*.*

Esse resultado expressa que o problema pode ser resolvido de forma recursiva no tempo: o valor atual depende do valor esperado futuro mais o ganho acumulado até esse instante. Sua versão infinitesimal conduz à equação de Hamilton–Jacobi–Bellman, dada por uma equação diferencial parcial não linear:

$$\partial_t H(t,x) + \sup_{u \in \mathcal{A}} \left(\mathcal{L}_t^u H(t,x) + F(t,x,u) \right) = 0, \qquad H(T,x) = G(x). \tag{8}$$

A condição terminal decorre diretamente da definição da função valor (6). O operador $\mathcal{L}^u$ é o gerador infinitesimal da difusão (Cartea et al., 2015, p. 108):

$$\mathcal{L}_t^u H(t,x) = \mu(t,x,u)\, \partial_x H(t,x) + \frac{1}{2}\sigma^2(t,x,u)\, \partial_{xx} H(t,x). \tag{9}$$

A otimização ocorre ponto a ponto no tempo, o que sugere que o controle ótimo pode ser escrito em forma de feedback, isto é, como função do estado atual e das derivadas da função valor. Assim, uma solução clássica da equação HJB é uma função $H(t,x)$ suficientemente regular ($C^{1,2}$) que satisfaz a equação acima. Sob condições adequadas, um teorema de verificação garante que essa solução coincide com a função valor do problema original (Cartea et al., 2015, p. 112). É essa estrutura teórica que será aplicada, na seção seguinte, ao problema clássico de alocação de portfólio de Merton.

4 O Problema de Merton

O problema de Merton constitui o exemplo clássico de otimização de portfólio em tempo contínuo no contexto de controle estocástico Merton (1971). Nesse modelo, um agente escolhe dinamicamente como alocar sua riqueza entre um ativo livre de risco e um ativo arriscado, com o objetivo de maximizar a utilidade esperada da riqueza terminal. Considere um mercado composto por um ativo livre de risco, com taxa de retorno constante r, e um ativo sob incerteza,

com preço S_t seguindo uma dinâmica estocástica. A dinâmica do ativo sob incerteza é dada por:

$$dS_t = (\mu - r)S_t\,dt + \sigma S_t\,dW_t, \tag{10}$$

onde μ é o retorno esperado, σ a volatilidade e W_t um movimento Browniano. O agente escolhe um processo π_t, representando o montante investido no ativo sob incerteza. A riqueza X_t^π evolui conforme:

$$dX_t^\pi = (rX_t^\pi + \pi_t(\mu - r))\,dt + \pi_t\sigma\,dW_t. \tag{11}$$

O objetivo é maximizar:

$$H(t,x,S) = \sup_{\pi\in\mathcal{A}_{t,T}} \mathbb{E}_{t,x,S}\left[U(X_T^\pi)\right], \tag{12}$$

onde U é a função de utilidade e $\mathcal{A}_{t,T}$ é o conjunto de estratégias admissíveis.

4.1 Solução

Aplicando o arcabouço da Seção 3 a esse problema específico, para uma estratégia π define-se:

$$H^\pi(t,x,S) = \mathbb{E}_{t,x,S}\left[U(X_T^\pi)\right]. \tag{13}$$

O processo bidimensional (X^π, S) possui gerador infinitesimal (Cartea et al., 2015, p. 110):

$$\mathcal{L}_t^\pi = (rx + (\mu - r)\pi)\partial_x + \frac{1}{2}\sigma^2\pi^2\partial_{xx} \tag{14}$$

$$+ (\mu - r)S\partial_S + \frac{1}{2}\sigma^2S^2\partial_{SS} + \sigma\pi S\partial_{xS}. \tag{15}$$

Pelo Princípio da Programação Dinâmica, a função valor deve satisfazer a equação de Hamilton–Jacobi–Bellman:

$$0 = \left(\partial_t + rx\partial_x + \frac{1}{2}\sigma^2S^2\partial_{SS}\right)H \tag{16}$$

$$+ \sup_\pi \left\{\pi\left((\mu - r)\partial_x + \sigma\partial_{xS}\right)H + \frac{1}{2}\sigma^2\pi^2\partial_{xx}H\right\}, \tag{17}$$

com condição terminal

$$H(T,x,S) = U(x), \tag{18}$$

dado que o termo no interior do supremo é quadrático em π. Assumindo que $\partial_{xx}H(t,x,S) < 0$ (condição de concavidade), e completando quadrados, pode-se mostrar que o máximo é atingido em:

$$\pi^* = -\frac{(\mu - r)\partial_x H + \sigma\partial_{xS}H}{\sigma^2\partial_{xx}H}. \tag{19}$$

Substituindo esse controle ótimo de volta na HJB, obtemos a EDP não linear:

$$0 = \left(\partial_t + rx\partial_x + \frac{1}{2}\sigma^2 S^2 \partial_{SS}\right) H - \frac{\left((\mu - r)\partial_x H + \sigma \partial_{xS} H\right)^2}{2\sigma^2 \partial_{xx} H}. \tag{20}$$

Como a condição terminal não depende de S, considera-se o ansatz:

$$H(t, x, S) = h(t, x).$$

A equação reduzida é:

$$0 = (\partial_t + rx\partial_x)h(t, x) - \frac{\lambda}{2\sigma}\frac{(\partial_x h)^2}{\partial_{xx} h}, \tag{21}$$

com

$$\lambda = \frac{\mu - r}{\sigma},$$

denominado preço de risco de mercado (índice de Sharpe).

O controle ótimo torna-se:

$$\pi^* = -\frac{\lambda}{\sigma}\left(\frac{\partial_x h}{\partial_{xx} h}\right). \tag{22}$$

4.2 Exemplo: Utilidade Exponencial

Para ilustrar a obtenção de uma solução explícita a partir da equação reduzida, considere a função de utilidade exponencial (Cartea et al., 2015, p. 111):

$$U(x) = -e^{-\gamma x}, \quad \gamma > 0. \tag{23}$$

Adota-se o ansatz:

$$h(t, x) = -\alpha(t)e^{-\gamma x \beta(t)}. \tag{24}$$

Com a condição terminal $\alpha(T) = \beta(T) = 1$, obtêm-se as equações:

$$\partial_t \alpha - \frac{\lambda}{2\sigma}\alpha = 0, \tag{25}$$

$$\partial_t \beta + r\beta = 0, \tag{26}$$

cujas soluções são:

$$\alpha(t) = e^{-\frac{\lambda}{2\sigma}(T-t)}, \quad \beta(t) = e^{r(T-t)}. \tag{27}$$

O controle ótimo é:

$$\pi^*(t) = \frac{\lambda}{\gamma\sigma}e^{-r(T-t)}. \tag{28}$$

Assim, a forma explícita da solução depende da função utilidade escolhida; casos clássicos incluem as utilidades exponencial e HARA (Hyperbolic Absolute Risk Aversion). Em particular, o resultado acima mostra que, para utilidade exponencial, a estratégia ótima é determinística no tempo, ilustrando uma das principais características do problema de Merton: a existência

de soluções em forma fechada sob hipóteses específicas. É justamente essa solução em forma fechada que serve de referência para a análise numérica desenvolvida na próxima seção.

5 Metodologia da Simulação

O objetivo deste capítulo é analisar o impacto da negociação discreta em comparação com o modelo contínuo de Merton (1969). Como o rebalanceamento contínuo é impraticável na prática, realiza-se uma simulação de Monte Carlo, seguindo a metodologia de van de Kruijs (2021), para quantificar a perda de utilidade decorrente da discretização, expressa como perda de equivalente de certeza (certainty equivalent loss, CE loss) em pontos-base (bp). O equivalente de certeza corresponde ao valor garantido que proporciona ao investidor o mesmo nível de utilidade que um pagamento futuro arriscado. Essa métrica permite interpretar perdas ou ineficiências diretamente em termos financeiros, facilitando a comparação entre diferentes estratégias de investimento.

5.1 Definição de Parâmetros e Significados

Os parâmetros utilizados na simulação e seus respectivos significados econômicos são os seguintes: r representa a taxa de juros livre de risco (risk-free rate); λ, o preço do risco, isto é, a compensação por unidade de volatilidade; σ, a volatilidade do ativo sob incerteza; γ, o coeficiente de aversão ao risco; w^*, a proporção ótima da riqueza investida no ativo de risco; T, o horizonte de investimento (maturidade); e dt, o passo de tempo na discretização. Os valores adotados para a simulação base são apresentados na Tabela 1. Destaca-se que tais valores não possuem caráter específico, sendo utilizados apenas para ilustrar a perda associada à discretização do tempo.

Tabela 1: Valores dos parâmetros

Parâmetro	**Valor**
r	0.02
λ	0.2
σ	0.25
γ	2
T	1
dt	1/250

5.2 Função de Utilidade e Equivalente de Certeza

Adota-se a função de utilidade CRRA, definida como:

$$U(x) = \begin{cases} \frac{x^{1-\gamma}}{1-\gamma} & \text{para } \gamma \geq 0, \gamma \neq 1 \\ \ln(x) & \text{para } \gamma = 1. \end{cases} \tag{29}$$

O equivalente de certeza (C) é o valor fixo no tempo T que resulta na mesma utilidade que a utilidade esperada do portfólio (van de Kruijs, 2021, p. 12) . Para a utilidade CRRA, ele é calculado como:

$$C = (E[U(X(T))](1-\gamma))^{\frac{1}{1-\gamma}}. \tag{30}$$

Para o caso contínuo de Merton, o equivalente de certeza (C^*) possui solução analítica fundamentada na esperança da utilidade ótima:

$$E[U(X_{opt}(T))] = \frac{X(0)^{1-\gamma}}{1-\gamma} \exp\left(\left[(r+\lambda\sigma)w^* + r(1-w^*) - \frac{1}{2}(\sigma w^*)^2\right] T(1-\gamma) + \frac{1}{2}(\sigma w^*)^2 T(1-\gamma)^2\right), \tag{31}$$

onde $w^* = \frac{\lambda}{\gamma\sigma}$ representa a proporção ótima investida no ativo de risco (van de Kruijs, 2021, p. 8). Observa-se que essa solução é constante ao longo do tempo e independente do nível de riqueza.

5.3 Dinâmica de Simulação

A trajetória do ativo de risco S é simulada discretamente através da solução da Equação Diferencial Estocástica via fórmula de Itô (3):

$$S(t+dt) = S(t) \exp\left(\left(r + \lambda\sigma - \frac{1}{2}\sigma^2\right) dt + \sigma\sqrt{dt}\epsilon\right), \tag{32}$$

onde $\epsilon \sim N(0,1)$ denota uma variável aleatória normal padrão que representa o choque estocástico proveniente das variações infinitesimais do movimento Browniano. A riqueza do portfólio $X(t)$ evolui entre os pontos de rebalanceamento t^* e t de acordo com a estratégia de pesos constantes:

$$X(t) = w^* X(t^*) \left(\frac{S(t)}{S(t^*)}\right) + (1-w^*) X(t^*) e^{r(t-t^*)}. \tag{33}$$

Para garantir a precisão estatística dos resultados, o método de Monte Carlo foi aplicado com 35 milhões de trajetórias do ativo de risco utilizando a equação (32). Adicionalmente, aplicou-se a técnica de variável de controle, que explora a alta correlação entre a estratégia discreta e a solução analítica de Merton para reduzir a variância das estimativas, conforme discutido em van de Kruijs (2021). A variável de controle Z é definida como:

$$Z = U(X(T)) - \alpha \left(U(X_{opt}(T)) - E[U(X_{opt}(T))]\right), \tag{34}$$

em que $U(X(T))$ representa a utilidade da riqueza terminal na estratégia discreta e $U(X_{opt}(T))$ corresponde à solução ótima contínua de Merton, cuja utilidade esperada é conhecida analiticamente. O parâmetro α é definido como a razão entre a covariância das utilidades e a variância da solução ótima, sendo escolhido de forma a minimizar a variância de Z.

5.4 Resultados da Simulação

As simulações foram realizadas na linguagem R, utilizando o ambiente RStudio (versão 1.3), em uma máquina equipada com processador Intel Ultra 9 285K (24 núcleos, frequência máxima de 5800 MHz) e 64 GB de memória RAM. O notebook contendo os códigos utilizados, bem como os dados apresentados na Tabela 2, estão disponíveis no repositório do GitHub Freiria (2025). Os resultados obtidos, expressos em termos da perda em equivalente certo, CE Loss (basis points) $= \left(\frac{C^\star - C}{C^\star}\right) \times 10{,}000$, com arredondamento na quarta casa decimal, são apresentados na Tabela 2.

Tabela 2: Comparação entre o consumo ótimo contínuo ($C^\star$) e o consumo obtido sob rebalanceamento discreto (C_{discrete}) para diferentes frequências de rebalanceamento da carteira. A perda em equivalente certo (CE loss) quantifica, em pontos-base, o custo da discretização em termos do consumo equivalente certo, com o respectivo intervalo de confiança de 95% obtido por simulação.

Estratégia	$C^\star$	$C_{\textbf{discrete}}$	**CE loss (bp)**	**IC de 95% (bp)**
Diária	1.0305	1.0305	0.0041	(0.0019; 0.0064)
A cada dois dias	1.0305	1.0305	0.0091	(0.0059; 0.0122)
Semanal	1.0305	1.0305	0.0232	(0.0183; 0.0281)
Mensal	1.0305	1.0304	0.0928	(0.0826; 0.1029)
Trimestral	1.0305	1.0304	0.2826	(0.2651; 0.3002)
Semestral	1.0305	1.0304	0.5427	(0.5181; 0.5674)
Anual	1.0305	1.0303	1.0755	(1.0411; 1.1099)

Utilizando os parâmetros apresentados na Tabela 1, a proporção ótima investida no ativo de risco é dada por $w^* = \frac{\lambda}{\gamma\sigma} = 0.4$. A Tabela 2 apresenta a comparação entre o consumo ótimo contínuo $C^\star$ e o consumo obtido sob rebalanceamento discreto C_{discrete} para diferentes frequências de rebalanceamento. Os resultados mostram que C_{discrete} permanece próximo de $C^\star = 1.030455$, calculado a partir da Equação (31), em todas as estratégias, indicando que a discretização introduz apenas pequenas perdas no consumo ótimo. Entretanto, a perda em equivalente certo ($CE\ Loss = C^\star - C$) aumenta conforme a frequência de rebalanceamento diminui: a estratégia diária apresenta perda de apenas 0.0041 bp, enquanto a anual atinge 1.0755 bp. Esse resultado evidencia o custo econômico associado a ajustes menos frequentes da carteira. Os intervalos de confiança de 95% são estreitos em todas as estratégias, indicando elevada precisão das estimativas obtidas por simulação. Dessa forma, os resultados confirmam que a solução discreta converge para a solução contínua de Merton à medida que a frequência de rebalanceamento aumenta, embora exista uma perda mensurável decorrente da discretização.

6 Conclusão

O desenvolvimento teórico permitiu a compreensão da otimização de portfólio no problema clássico de Merton, por meio do Princípio da Programação Dinâmica e da equação de Hamilton–Jacobi–Bellman (HJB), estabelecendo uma referência analítica para a solução ótima em tempo

contínuo. Os resultados das simulações de Monte Carlo, com geração de trajetórias do ativo de risco e uso de variável de controle, indicam que a discretização das estratégias de rebalanceamento produz perdas econômicas reduzidas em altas frequências, mas crescentes à medida que a frequência diminui, conforme evidenciado pela *CE loss* em *basis points*. Dessa forma, estratégias discretas frequentes aproximam-se bem da solução contínua, enquanto rebalanceamentos menos frequentes implicam custos mais relevantes.

Referências

Björk, T. (2019). *Arbitrage Theory in Continuous Time*. Oxford Finance Series. OUP Oxford.

Cartea, Á., Jaimungal, S., and Penalva, J. (2015). *Algorithmic and High-Frequency Trading*. Cambridge University Press.

Freiria, G. V. (2025). Ic_fapesp_2025. Repositório GitHub. Disponível em: `https://github.com/guilhermevalverdefreiria/IC_FAPESP_2025`. Acesso em: 22 jul. 2026.

Hull, J. C. (2016). *Opções, Futuros e Outros Derivativos*. Bookman Editora.

Merton, R. C. (1969). Lifetime portfolio selection under uncertainty: The continuous-time case. *The Review of Economics and Statistics*, 51(3):247–257.

Merton, R. C. (1971). Optimum consumption and portfolio rules in a continuous-time model. *Journal of Economic Theory*, 3(4):373–413.

Pham, H. (2009). *Continuous-time Stochastic Control and Optimization with Financial Applications*, volume 61. Springer Science & Business Media.

van de Kruijs, J. (2021). Merton's portfolio problem with discrete trading and multiple risky assets. Master of science in quantitative finance and actuarial sciences, Tilburg University, Tilburg, Netherlands.